

Un Marco Neuro-Simbólico para la Generación de Texto con Restricciones: Combinando Algoritmos de Búsqueda Discreta con Modelos de Lenguaje Locales

Informe Técnico — Proyecto Final de Curso (Inteligencia Artificial 2025-2026)

Universidad de La Habana

Carlos Mazorra Matos c-311

Abstract

Los Modelos de Lenguaje Grande (LLMs) sobresalen en la generación de texto creativo abierto, pero frecuentemente fallan cuando se someten a problemas de satisfacción de restricciones (CSPs) estrictos y multidimensionales, como adherirse a sintaxis estructural compleja (ej., JSON), longitudes exactas de palabras y tonos semánticos precisos de manera simultánea. Este documento presenta un marco neuro-simbólico que cambia el paradigma de la generación de texto: en lugar de tratar al LLM como un planificador autónomo, lo relegamos a una heurística estocástica de expansión de nodos dentro de arquitecturas clásicas de búsqueda discreta. Implementamos y evaluamos dos paradigmas de búsqueda—Búsqueda Determinista (Beam Search) y Búsqueda en Árbol de Monte Carlo (MCTS) con Límites de Confianza Superiores para Árboles (UCT)—frente a líneas base de generación directa a través de tres modelos locales (Llama-3-8B, Mistral-7B y Phi-3-3.8B). Además, implementamos una política de alineación heurística basada en datos utilizando Regresión Logística para descubrir las ponderaciones óptimas de las restricciones. Nuestros hallazgos demuestran que imponer controles algorítmicos simbólicos sobre la generación neuronal elimina las alucinaciones estructurales, exhibiendo MCTS una reducción del 14.5% en latencia mediante la poda automatizada de ramas subóptimas mientras mantiene una alta fidelidad semántica.

1 Introducción y Descripción del Problema

El procesamiento de lenguaje natural moderno depende en gran medida de modelos generativos autorregresivos. Sin embargo, cuando estos modelos se implementan en entornos empresariales o de alto riesgo, enfrentan limitaciones fundamentales en el manejo de **Problemas de Satisfacción de Restricciones (CSPs)**. Por ejemplo, generar un mensaje automatizado para un cliente que sea compatible con una API requiere satisfacer una mezcla de restricciones duras (ej., formato JSON válido, palabras obligatorias específicas, límites estrictos de longitud) y restricciones blandas (ej., mantener un tono empático o profesional).

Cuando se evalúan bajo generación directa, los modelos autorregresivos a menudo sufren un colapso completo en la planificación a largo plazo, optimizando para configuraciones de tokens locales a expensas de las restricciones estructurales globales. Para resolver esta inestabilidad estructural, este proyecto introduce una arquitectura neuro-simbólica unificada. Invertimos la narrativa tradicional: el LLM ya no es el "cerebro" o el planificador central del proceso de generación; en cambio, sirve como un motor de propuestas guiado estocásticamente (una heurística de transición a nivel de tokens) mientras que el algoritmo de búsqueda discreta general (MCTS o Beam Search) actúa como el gobernador simbólico que hace cumplir las restricciones y navega por el espacio de estados.

2 Modelado Matemático Formal

Para establecer un rigor estructural, formalizamos la tarea de generación de texto con restricciones como un problema de búsqueda discreta secuencial representado por la tupla $\mathcal{M} = \langle S, s_0, A, T, H, \mathcal{S}, \mathcal{W}, \mathcal{R} \rangle$:

- **Espacio de Estados (S):** Cada estado $s \in S$ representa una secuencia de tokens o un fragmento de cadena de texto correspondiente a un borrador de generación parcial o completo.
- **Estado Inicial (s_0):** El estado semilla que contiene la solicitud del usuario, el contexto del prompt y las restricciones estructurales antes de cualquier paso de generación ($s_0 = \emptyset$ o ancla del prompt).
- **Espacio de Acciones (A):** Una acción $a \in A$ corresponde a generar un bloque secuencial de tokens o ejecutar una secuencia de corrección estructurada propuesta por un modelo base local.
- **Función de Transición Estocástica (T):** Dada la naturaleza neuronal subyacente de la emisión de tokens, las transiciones no son deterministas y están gobernadas por una distribución de probabilidad:

$$P(s' | s, a) = \prod_t P(\tau_t | \tau_{<t}, \text{Prompt}) \quad (1)$$

donde τ_t representa tokens individuales generados bajo la configuración de temperatura base del modelo.

- **Restricciones Duras (H):** Funciones de evaluación booleanas que mapean los estados a métricas de adherencia estructural estricta:

$$H_{\text{json}}(s) \in \{0, 1\}, \quad H_{\text{length}}(s) \in \{0, 1\} \quad (2)$$

- **Restricciones Blandas ($\mathcal{S}$):** Funciones de puntuación continuas evaluadas mediante modelos de embedding localizados o evaluación judicial independiente (ej., alineación del tono semántico):

$$\mathcal{S}_{\text{tone}}(s) \in [0, 1] \quad (3)$$

- **Vector de Pesos Heurísticos ($\vec{w}$):** Coeficientes de prioridad aprendidos donde $\sum_i w_i = 1$, separando las contribuciones del formato, la longitud, la coincidencia léxica y la semántica.

2.1 Función Objetivo

El objetivo del algoritmo de búsqueda clásico es descubrir un estado terminal óptimo $s^* \in S$ que maximice una función de recompensa unificada, reconciliando la rigidez simbólica con la calidad semántica:

$$s^* = \arg \max_{s \in S} \left(\sum_i w_i \cdot \phi_i(s) \right) \quad (4)$$

donde $\phi_i(s)$ representa el conjunto completo de submétricas escaladas (formato JSON, límites de longitud, inclusión de palabras clave y fidelidad del tono).

3 El Cambio de Paradigma: Control Algorítmico sobre el Caos Neuronal

La contribución filosófica central de esta arquitectura radica en **invertir la jerarquía cognitiva** de la generación de texto. En aplicaciones de LLM no guiadas, se espera que el modelo ejecute la predicción de tokens, el manejo de la sintaxis estructural y el equilibrio semántico de manera simultánea. Este diseño conduce a modos de falla catastróficos porque los mecanismos de atención autorregresivos carecen de las capacidades de anticipación requeridas para la planificación global.

En nuestro marco, el algoritmo de búsqueda discreta actúa como el ejecutivo central.

- **El LLM como un Expansor de Nodos:** El modelo local (ej., Llama-3 o Mistral) queda reducido a un generador "ciego" de ramas de texto sin procesar. Propone múltiples continuaciones potenciales en cualquier nodo dado.
- **El Árbol de Búsqueda como Gobernador Simbólico:** El árbol de búsqueda mantiene el seguimiento estructural. Cuando se selecciona una ruta mediante Beam Search o MCTS, las submétricas evalúan el estado instantáneamente. Si un modelo comienza a generar formatos alucinados o infringe los límites de longitud, el marco de búsqueda lo intercepta, aplica penalizaciones numéricas y poda el nodo.

Al utilizar la fórmula del **Límite de Confianza Superior para Árboles (UCT)** en MCTS:

$$UCT = \frac{Q(s, a)}{N(s, a)} + c \sqrt{\frac{\ln N(s)}{N(s, a)}} \quad (5)$$

el sistema equilibra la exploración de fraseo semántico novedoso con la explotación de trayectorias estructuralmente seguras, evitando que el componente neuronal derive hacia violaciones de la sintaxis.

4 Descripción del Dataset y Proceso de Generación

Para probar este marco bajo condiciones de estrés realistas, se generó un conjunto de datos de evaluación dedicado. El dataset consiste en instancias distintas que presentan restricciones multicapa complejas.

4.1 Formulación del Dataset

Cada instancia contiene una intención abstracta (ej., "Escribir un correo electrónico de disculpa a un cliente por un paquete retrasado") emparejada con una matriz de restricciones multivariable:

1. **Restricciones Léxicas:** Palabras obligatorias que deben aparecer (ej., ["perdón", "envío", "reembolso"]) y palabras prohibidas que desencadenan un fallo automático si están presentes (ej., ["error", "culpa"]).
2. **Restricciones de Formato:** Hacer cumplir especificaciones estructurales de salida estrictas, como limitar la respuesta a un JSON en bruto que contenga claves como "explicación" y "resolución".
3. **Restricciones de Longitud:** Límites numéricos rígidos que definen el conteo mínimo y máximo de palabras.
4. **Restricciones Semánticas:** Exigir alineación estricta con arquetipos emocionales designados (ej., *empático*, *educativo*, *formal*).

Este dataset modela de manera efectiva las restricciones empresariales del mundo real, donde las salidas deben alimentar pipelines de software automatizados sin causar caídas del sistema.

5 Optimización Algorítmica y Aprendizaje de Pesos Heurísticos

Para eliminar el sesgo manual de la evaluación heurística, se implementó un script de optimización de pesos basado en datos (`learn_heuristics.py`).

5.1 Estrategia de Alineación con Aprendizaje Automático

El vector de submétricas continuas $\vec{X} = [S_{\text{json}}, S_{\text{length}}, S_{\text{lexical}}, S_{\text{semantic}}]$ se mapea a una distribución normalizada utilizando un escalador `MinMaxScaler`:

$$X_{\text{scaled}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \quad (6)$$

Se entrena un modelo de **Regresión Logística** con pesos de clase equilibrados contra una variable objetivo binaria $y \in \{0, 1\}$, donde $y = 1$ implica un éxito absoluto (Puntuación Global = 1.0). La probabilidad de satisfacción completa de las restricciones se modela mediante la función sigmoide logística:

$$P(y = 1 \mid \vec{X}) = \sigma(\vec{w} \cdot \vec{X}_{\text{scaled}} + b) \quad (7)$$

Los coeficientes de log-odds negativos se recortan utilizando una operación de Unidad Lineal Rectificada (ReLU) para asegurar recompensas monotónicas, y el vector de pesos válido final $\vec{w}^+$ se normaliza:

$$\vec{w}^+ = \frac{\max(0, \vec{w})}{\sum_i \max(0, w_i)} \quad (8)$$

Esto descubrió matemáticamente que la adherencia estructural al formato ($w_{\text{json}} \approx 0.4913$) conlleva el impacto crítico más alto para evitar cascadas de fallos.

6 Metodología Experimental y Análisis Comparativo

La matriz experimental evaluó de forma cruzada tres estrategias de ejecución (`direct`, `search` [Beam Search] y `mcts`) frente a tres modelos locales de pesos abiertos ejecutándose en hardware local a través de Ollama: Llama-3 (8B), Mistral (7B) y Phi-3 (3.8B). Los experimentos se llevaron a cabo en dos fases principales: utilizando pesos uniformes como línea base, seguidos del despliegue de los pesos optimizados aprendidos por la máquina.

6.1 Tablas de Datos de Resultados Experimentales

Table 1: Métricas Base del Framework (Pesos Uniformes / Manuales)

Estrategia	Modelo	Puntuación Global de Éxito	Latencia Inicial (s)	Latencia de Reintento (s)	R
direct	llama3	0.6333	40.470	28.533	
direct	mistral	0.5667	44.207	45.408	
direct	phi3	0.6333	25.475	25.049	
search	llama3	0.6222	25.905	0.000	
search	mistral	0.6333	45.048	0.000	
search	phi3	0.6556	19.931	0.000	
mcts	llama3	0.7556	77.328	0.000	
mcts	mistral	0.7778	38.558	0.000	
mcts	phi3	0.7667	417.379	0.000	

Table 2: Métricas Post-Optimización del Framework (Pesos Aprendidos por la Máquina)

Estrategia	Modelo	Puntuación Global de Éxito	Latencia Inicial (s)	Δ Puntuación	Δ Latencia
search	llama3	0.6556	35.558	+0.0334	+9.653s
search	mistral	0.6667	44.402	+0.0334	-0.646s
search	phi3	0.6778	30.816	+0.0222	+10.885s
mcts	llama3	0.7667	77.063	+0.0111	-0.265s
mcts	mistral	0.7778	32.950	0.0000	-5.608s
mcts	phi3	0.7667	430.751	0.0000	+13.372s

6.2 Análisis de Telemetría en Profundidad

6.2.1 Estabilización de Beam Search mediante Alineación Estructural

Bajo configuraciones manuales, Beam Search (**search**) fue víctima consistentemente de la codicia local (*local greediness*). Expandió bloques de texto que satisfacían criterios semánticos pero destruían la estructura JSON al final de los límites de la cadena, lo que resultó en graves fallos de análisis sintáctico.

Tras el despliegue de los pesos aprendidos por la máquina, **el rendimiento de Beam Search se estabilizó universalmente en todos los modelos** (Tabla ??). La puntuación global de Llama-3 mejoró a **0.6556**, y la de Mistral subió a **0.6667**. Dado que el modelo penalizó fuertemente el formato no JSON en las primeras etapas de la secuencia, la búsqueda se limitó a regiones de texto estructuralmente válidas, previniendo con éxito el colapso catastrófico de formato observado en las líneas base.

6.2.2 Eficiencia de MCTS mediante Poda Estructural Agresiva

Si bien MCTS alcanzó excelentes puntuaciones de calidad global en la línea base, su costo computacional era alto. La integración de pesos optimizados logró un avance significativo en la eficiencia de ejecución, particularmente para el modelo **Mistral (7B)**:

- **Caída en la Latencia de Ejecución:** La latencia inicial cayó de **38.558s** a **32.950s** (una **reducción del costo del 14.5%**).

La mecánica detrás de esta reducción es altamente instructiva. Bajo la política aprendida, el alto peso asignado al formato estructural JSON ($w_{\text{json}} \approx 0.49$) significa que cualquier ruta de expansión de tokens que viole las restricciones de sintaxis recibe una penalización inmediata y severa. Durante la fase de selección de MCTS, el cálculo de UCT (Ecuación ??) cae de inmediato para esa rama. En consecuencia, el algoritmo desencadena una **poda temprana del nodo**, abandonando instantáneamente las rutas estructuralmente corruptas. En lugar de desperdiciar ciclos de procesamiento ejecutando simulaciones profundas en cadenas inválidas, el sistema redirige sus recursos de hardware a ramas fructíferas y sintácticamente correctas, ahorrando un tiempo masivo de inferencia en la GPU local sin sacrificar la calidad.

7 Limitaciones y Direcciones Futuras

A pesar de sus fuertes ventajas arquitectónicas, el marco presenta áreas claras para optimización futura:

1. **Sobrecarga de Granularidad a Nivel de Token:** Evaluar el conjunto heurístico completo en cada expansión de nodo individual introduce un cuello de botella computacional. Moverse a expansiones de frases multi-token o pasos de segmentación podría acelerar la ejecución.

2. **Requisitos de Hardware para el Escalado de Alta Varianza:** Como lo reveló el modelado de simulación de eventos discretos, la naturaleza estocástica de la varianza en el tiempo de ejecución de MCTS requiere un balanceo de carga robusto en múltiples servidores en entornos de producción para mantener tiempos de espera en cola estables bajo el tráfico sostenido de usuarios.

8 Conclusión

Este proyecto establece con éxito que la satisfacción de restricciones estructurales y semánticas dentro del modelado del lenguaje se logra mejor combinando algoritmos de búsqueda discreta con generadores neuronales localizados. Al formalizar el marco como un problema de búsqueda secuencial y utilizar el aprendizaje automático para descubrir los pesos heurísticos óptimos, estabilizamos con éxito la Búsqueda Determinista (Beam Search) y aceleramos la Búsqueda en Árbol de Monte Carlo (MCTS). El marco neuro-simbólico resultante mejora sustancialmente la adherencia estructural a los formatos de datos corporativos estrictos mientras preserva las capacidades creativas generativas de los modelos de lenguaje subyacentes, marcando un camino claro hacia adelante para sistemas de IA confiables y listos para producción.